

多尺度YOLOv5的交通灯检测算法

钱 伍, 王国中, 李国平

(上海工程技术大学 电子电气工程学院, 上海 201620)

摘 要: 交通灯检测作为自动驾驶任务中的关键技术,直接关系到智能汽车的行驶安全。针对交通灯尺度小、环境复杂造成的检测困难问题,提出一种多尺度YOLOv5的交通灯检测方法。首先使用复合数据增强方法对模型输入进行增强处理,增加输入的复杂性;然后设计多尺度代替固定尺度训练,均衡模型的学习能力;最后构建多尺度特征融合网络,将4倍、8倍、16倍和32倍下采样信息融合,建立多尺度检测层。为增强特征融合能力,引入远跳链接传递不同级别信息,直接提升了模型对小目标的检测能力。实验结果证明,在采集的数据集上,改进YOLOv5的检测速度最快可达到9.5ms, mAP达到99.8%,相比YOLOv5提高了17%,在Bosch数据集上, mAP增加了6.5%,实现了对交通灯的实时与高精度检测。

关键词: 目标检测; YOLOv5; 交通灯检测; 多尺度特征; 实时检测

DOI: 10.11907/rjdk.212241

开放科学(资源服务)标识码(OSID):

中图分类号: TP391.4

文献标识码: A

文章编号: 1672-7800(2022)009-0019-07



Traffic Light Detection Algorithm Based on Multi Scale YOLOv5

QIAN Wu, WANG Guo-zhong, LI Guo-ping

(College of Electronic and Electrical Engineering, Shanghai University of Engineering Science, Shanghai 201620, China)

Abstract: Traffic light detection, a core technology in automatic driving, is directly related to the safety of intelligent vehicles. An improved YOLOv5 traffic light detection method is proposed to handle small-size-light recognition and complex-environment anti-interference. In this paper, composite data augmentation is used to increase model input capacity and complexity. Multi-scale training is designed to replace fixed scale training so that the learning ability of the model can be balanced. The proposed also fuses the samples at 4, 8, 16 and 32 times respectively to build a multi-scale detection layer. In order to improve the feature fusion, remote-jump links are introduced to convey different levels of information, which directly improves the detecting precision of small targets. At last, experiments show that the fastest detection speed of improved YOLOv5 can reach 9.5ms, and mAP can reach 99.8%, which is 17% higher than that of YOLOv5, and 6.5% more mAP is added on Bosch dataset, achieving a real-time and high-precision detection of traffic lights.

Key Words: object detection; YOLOv5; traffic light detection; multi-scale feature; real-time detection

0 引言

近年来,计算机视觉和深度学习的快速发展使很多领域都取得了重大突破,其中自动驾驶领域也发展十分迅猛。基于视觉的交通灯检测、行人检测和车辆检测作为自动驾驶的核心技术受到众多学者关注。对交通灯的准确定位与类别识别能够获取路口信息,为自动驾驶汽车的决策提供重要的数据支持,减少了汽车行驶的安全隐患。因

此,一个具有可靠性与实时性的交通灯检测算法能够保障自动驾驶汽车的行驶安全,避免交通事故发生。

传统交通灯检测算法通常从颜色特征出发,并结合机器学习、图像处理等方法,其中 Hough^[1]、SVM(Support Vector Machine)^[2]和 Tophat^[3]等方法被广泛使用。如田谨等^[4]提出一种箭头形交通信号灯识别方法,将多种机器学习方法相结合,在模板匹配下实现对箭头形交通信号灯的识别。

随着深度学习的发展,基于卷积神经网络的目标检测

收稿日期: 2017-03-20

基金项目: 张江国家自主创新示范区专项(ZJ2020-ZD-009)

作者简介: 钱伍(1995-),男,上海工程技术大学电子电气工程学院硕士研究生,研究方向为目标检测;王国中(1962-),男,博士,上海工程技术大学电子电气工程学院教授、硕士生导师,研究方向为视频编解码;李国平(1974-),男,博士,上海工程技术大学电子电气工程学院副教授、硕士生导师,研究方向为机器学习与识别。

算法被提出。叶飞等^[5]通过改进 YOLOv3^[6]实现了对行人的检测,且精度提高了 5%;严广宇等^[7]将 Faster R-CNN^[8]与 Deeplab v3+网络相结合,实现了对共享单车类别与违停的检测,其中类别检测 mAP(mean Average Precision)达到 72.36%,违停检测的平均准确率为 89.11%;Zhu 等^[9]从 10 万张街景图中构建交通标志数据集 TT100K,使用 6 层卷积神经网络实现了交通标志检测;Kim 等^[10]将交通灯的颜色部分与 R-CNN^[11]和 R-FCN^[12]相结合,把交通灯检测应用于汽车辅助驾驶系统中;Liu 等^[13]建立了自己的数据集,提出基于改进 YOLOv3 的检测交通灯,改进后模型的检测速度达到 59FPS, mAP 达到 91.12%。基于深度学习的目标检测算法能够自动提取特征,且对颜色信息不敏感。但这些方法在特征提取过程中不可避免地会对图像进行下采样,且对小目标的检测能力差。

以交通灯尺度小、环境复杂为研究重点,本文采集现实场景中的交通灯图像建立数据集。基于 YOLOv5^[14]模型,提出多尺度训练与多尺度融合输出的方法,增加了模型对小目标的检测能力。多尺度 YOLOv5 检测速度最快可达到 9.5ms, mAP 最高可达到 99.8%。在 Bosch 数据集^[15]上,改进方法直接提高了 6.5% 的检测性能,最后以消融实验验证改进方法的有效性。

1 数据获取与相关算法

1.1 数据集制作

在自动驾驶和辅助驾驶任务中, BDD100K^[16]、KITTI^[17]和 Cityscapes^[18]数据集是首选的公共数据集。由于其均采集自于国外,与国内交通环境具有很大差异,且没有对交通灯进行类别标注,因此以这些数据集为研究背景的模型很难适用于国内的交通环境。清华大学发布的 TT100K^[9]以交通标志为主,而没有对交通灯进行标注,不能作为交通灯检测的数据集。长沙理工大学发布的 CCTS-DB^[19]将常见的交通标志标注为 3 种,也没有对交通灯进行标注。

针对国内交通环境,本文采集了 10 万张现实中的交通灯影像,从中筛选出 16 333 张图像,并使用 Labelme 工具进行标注,制作成交通灯检测数据集,以 8:2 的比例划分为训练集和测试集,部分样本数据如图 1 所示。数据集包含时间、类别和尺度属性。在时间分布上,白天、夜晚、黎明/黄昏的图像个数分别是 9 548、5 620 和 1 165;在标签类别分布上,红灯有 24 937 个标签,黄灯有 787 个,绿灯有 12 433 个, None 有 12 450 个;在标签尺度分布上,小中大 3 种尺度的比例为 29 875:19 602:1 130。

1.2 YOLOv5

YOLOv5 延续了网格预测方法,将图像划分为 $S \times S$ 的网格,每个网格负责预测 B 个边界框和 C 个条件类别概率,在输出结果中还要计算预测框的置信度值。在正负样本




Fig. 1 Sample images of traffic light data set

图 1 交通灯数据集样本

选择上, YOLOv5 抛弃了基于最大 IOU (Intersection Over Union) 的匹配规则,而是直接通过宽高比选取正负样本,相比于 YOLOv3/v4^[20],正样本至少增加了 3 倍。

如图 2(a)所示, YOLOv5 将图像固定为 640*640 尺度输入网络,经过 Focus 层将图像的宽高信息转化为通道信息,既减少了计算量,又增加了感受野。经过多个正则卷积层和 BottleneckCSP 层提取特征,将 8 倍、16 倍和 32 倍下采样后的特征图送入 PANet^[21]网络进行特征融合。最后,检测头对融合后的高级语义信息进行分类与回归,给出置信度值。图 2 中的 Conv 用于下采样和改变通道数目, BottleneckCSP 是参考 CSPNet^[22]设计的特征提取层。

YOLOv5 拥有 4 种规模,分别记为 YOLOv5s、YOLOv5m、YOLOv5l 和 YOLOv5x。随着模型的深度和宽度逐渐增加,特征提取与检测能力也随之提高。因为 YOLOv5 具有推理速度快、自适应锚框和高召回率等特点,十分适合交通灯检测任务,所以本文以 YOLOv5 的 4 种模型为基础,针对 YOLOv5 的不足进行改进。针对 YOLOv5 模型泛化能力差,容易出现过拟合,且采集的数据集规模不大的问题,本文提出复合数据增强策略;针对 YOLOv5 的输入是固定尺度,提取到的特征信息有限的问题,本文提出多尺度代替固定尺度的训练方式;针对 YOLOv5 将 3 种尺度语义信息送入检测头,对小目标的检测能力不足的问题,本文提出多尺度特征融合的改进方式,并引入远跳连接传输语义信息。

2 多尺度 YOLOv5

2.1 复合数据增强

YOLOv5 使用 mosaic^[20]方法对图像进行增强处理。考虑到本文制作数据集的规模不大,且环境复杂多样,因此在 mosaic 基础上提出复合数据增强方式对模型的输入进行增强,以提高模型输入的复杂性、增加训练难度,从而提升模型的泛化能力。使用 mosaic、透视变换与颜色变换相结合的方式对输入进行增强,复合数据增强流程如图 3 所示。具体步骤如下:①读取当前需要增强的图像 f ,长宽分别是 l 和 d ;②从数据集中随机读取 3 张不同于 f 的图像 f_1 、 f_2 和 f_3 ;③以 $2l$ 为边生成矩形画布,将 4 副图像拼接得到 mosaic 结果 g_1 ;④使用透视变换对 g_1 随机进行旋转、平移和缩放,得到 g_2 ;⑤从 g_2 中随机截取与模型输入尺度相同




Fig. 2 Network structure of YOLOv5 and MS-YOLOv5

图2 YOLOv5与MS-YOLOv5网络结构

的图像,对其进行颜色变换,随机调整图片的色调、饱和度和明度得到 g_3 ;⑥以0.5和0.3的概率对 g_3 进行水平翻转与垂直翻转,得到 g_4 ;⑦将 g_4 作为复合数据增强结果输入模型。




Fig. 3 Composite data augmentation process

图3 复合数据增强流程

经过复合数据增强后,模型的输入由一幅固定图像变成多幅图像的随机组合。与mosaic相比,增强后的图像更为复杂,模型能够学习到更多复杂特征,提升了模型对不同场景的适应能力。消融实验结果证明,复合数据增强方法的mAP提高了5.2%,相比mosaic增加了0.8%。

2.2 多尺度训练

在卷积神经网络中,通常通过增加模型输入尺寸以提高模型对小目标的检测能力。但是该方法会带来新问题:①模型计算量随输入的增加而成倍增加,使训练和推理速度变慢;②模型感受野随之变小,对大尺度目标的检测能

力下降。

针对YOLOv5的固定尺度训练,本文提出多尺度训练方法,将目标可能出现的不同尺度送入网络进行训练学习。在多尺度训练过程中,模型不会侧重于学习小尺度或大尺度,而是较均衡地学习不同尺度的信息,对不同尺度的目标都具有检测能力。

在训练阶段,将数据分批次送入模型。在当前的batch下,按照公式(1)选择图像尺度作为训练尺度,图像被缩放到训练尺度后进行前向推理和反向学习。在测试阶段,以固定尺度作为模型输入尺度,对模型进行测试。消融实验结果表明,多尺度训练可显著提高模型的特征提取能力,在没有数据增强的情况下,mAP可提高5.8%。

$$out = 32 * \lceil input * \lambda \div 32 \rceil \quad (1)$$

其中, $input$ 是模型固定尺度, λ 是随机数, out 是模型输入尺度。

2.3 多尺度特征融合与输出

YOLOv5借鉴PANet的思想对主干网络提取到的基础特征进行融合(见图4(a)),生成高层特征信息送入检测器计算损失。由于交通灯尺度集中于小尺度,较多信息分布在基础特征中,所以YOLOv5会出现较多漏检测的情况。针对小尺度目标检测,本文受BiFPN^[23]启发,设计了多尺度的特征融合(见图2(b))代替YOLOv5的PANet。将4倍、8倍、16倍和32倍采样信息作为输入,生成4种不同尺

度的语义信息用于分类与回归,其中4倍采样和8倍采样结果用于检测小尺度目标,16倍采样结果用于检测中尺度目标,32倍采样结果用于检测大尺度目标。




Fig. 4 Feature fusion network

图4 特征融合网络

多尺度特征融合网络结构如图4(b)所示,在融合过程中通过自上而下传递信息以强化中间两层特征。最后生成多尺度高级语义信息,引入远跳连接方式传递原始基础特征,并将低级特征与高级语义信息再次融合,以强化高级语义信息中的低级特征。

多尺度融合输出后,生成的高级语义信息被送入检测器,按照4种尺度的方式重新计算回归损失 L_{CIOW} 、分类损失 L_{cls} 和置信度损失 L_{obj} 。其中,分类损失使用交叉熵函数作为损失函数,回归损失使用CIOU损失作为损失函数。计算方法如下:

$$L_{CIOW} = \sum_{i=0}^L 1 - IOU + \frac{\rho^2(b, b^{gt})}{D^2} + \partial v \quad (2)$$

$$\partial = \frac{v}{1 - IOU + v} \quad (3)$$

$$v = \frac{4}{\pi^2} (\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h})^2 \quad (4)$$

$$L_{cls} = - \sum_l \sum_{i=0}^n \sum_{j=0}^{nc} [\hat{C}_{ij} \log_e(C_{ij}) + (1 - \hat{C}_{ij}) \log_e(1 - C_{ij})] \quad (5)$$

$$L_{obj} = - \sum_l W_l \sum_{m=1}^M \sum_{n=1}^N I_{mn}^{obj} \sum_c [\hat{P}_{mn}(c) \log_e(P_{mn}(c)) + (1 - \hat{P}_{mn}(c)) \log_e(1 - P_{mn}(c))] \quad (6)$$

$$Loss = (L_{CIOW} * h_{box} + L_{cls} * h_{cls} + L_{obj} * h_{obj}) * s * bs \quad (7)$$

其中, IOU 是预测框与真实框的交并比; $\rho^2(b, b^{gt})$ 表示预测框与真实框中心点之间的欧式距离; D 表示同时包含预测框和真实框的最小闭合矩形区域对角线距离; L 是检测层个数; w 、 h 是预测框的宽和高; w^{gt} 、 h^{gt} 是真实框的宽和高; n 是预测框个数; nc 是一个锚框下的预测框个数; C 是预测类别; $\hat{C}$ 是目标真实类别; M 、 N 分别是网格的宽和高; I_{mn}^{obj} 表示网格位置(M , N)是否负责预测该目标,取0或者1; P 是预测概率; h_{box} 、 h_{cls} 和 h_{obj} 分别是回归损失、分类损失与置信度损失系数; s 是检测层的输出尺度系数; bs 是批量

大小。

如图2(b)所示,多尺度YOLOv5流程如下:①使用提出的复合数据增强对模型输入进行增强;②使用多尺度训练方法随机为增强结果选择尺度,并输入模型;③主干网络提取特征信息,将4倍、8倍、16倍和32倍采样提取的信息作为基础特征;④将4种不同尺度特征送入设计的特征融合网络,生成多尺度的高级语义信息;⑤对多尺度高级语义信息计算损失,通过反向传播训练模型权重。

3 实验与结果分析

3.1 实验环境与网络训练

模型的训练在Ubuntu18.04操作系统、Pytorch框架下完成,硬件平台为:Nvidia Tesla V100 PCIE 32GB GPU,处理器为: Intel(R) Xeon(R) Silver 4214R CPU 2.4GHz,软件环境为: CUDA10.1, Python3.8。实验训练300个epochs,初始学习率为0.001,学习率衰减系数为0.2,采用余弦退火衰减方式,设置动量常数为0.937, batch大小为32,回归损失系数为0.05,分类损失系数为0.5,置信度损失系数为1.0。实验训练了数据集中的13 066张图像,测试了3 267张图像,在训练过程中对每个epoch的训练结果进行验证。为验证模型的有效性,本文还在Bosch小尺度交通灯数据集上测试模型性能。

为客观评估模型性能,本文计算了模型的混淆矩阵,并通过混淆矩阵计算常用的算法评估指标——召回率(Recall)和mAP($IOU=0.5$),计算公式如下:

$$Precision = \frac{Q_{TP}}{Q_{TP} + Q_{FP}} \quad (8)$$

$$Recall = \frac{Q_{TP}}{Q_{TP} + Q_{FN}} \quad (9)$$

$$AP = \frac{1}{101} \sum_{i=0}^{100} Precall(Recall = \frac{i}{100}) \quad (10)$$

$$mAP = \sum_{c=0}^{classes} AP(c) \quad (11)$$

其中, Q_{TP} 是正确检测的目标, Q_{FP} 是模型误检测的目标, Q_{FN} 是模型漏检测的目标。

如图5(a)所示,MS-YOLOv5l在训练开始的前20个epochs,训练损失快速下降到0.045。从第40个epoch开始,模型损失下降逐渐变缓,模型开始趋于收敛,损失值在0.02附近浮动。改进后模型的损失稳步下降,其中前期下降速度较快。训练过程中,MS-YOLOv5l的验证结果如图5(b)所示。验证集的mAP在前20个epochs快速上升,达到0.96。随着模型的收敛,mAP的上升速度也逐渐变慢,最后趋于稳定。通过验证mAP曲线,可知模型未发生过拟合。

3.2 实验结果

在不同场景下分别对YOLOv5和MS-YOLOv5进行测试。如图6所示,在逆光场景下,YOLOv5漏检严重,对被




Fig. 5 Model training process

图5 模型训练过程

遮挡住的目标没有检测能力。而 MS-YOLOv5 不仅检测出红灯的位置和类别,而且,当目标被大范围遮挡时,也能够正确检测其位置。如图 7 所示,在夜晚场景下,受到汽车尾灯影响,YOLOv5 很难识别交通灯,因此漏检了两个交通灯。MS-YOLOv5 则准确检测出每一个交通灯的类别,对交通灯的定位也没有受到干扰。在图 8 中,两种算法都能够正确检测交通灯,但是 MS-YOLOv5 对每个交通灯的置信度更高,对预测坐标框和类别有更高的确信度。由图 9 可知,在交通灯尺度极小的场景下,YOLOv5 的检测性能骤降,而 MS-YOLOv5 不仅能准确识别每一个交通灯,而且提高了置信度分数。

表 1 量化了本文数据集上的模型检测性能,通过计算模型在测试集上的召回率、mAP 和检测速度来评估模型性能。YOLOv5x 作为 YOLOv5 最好的模型,召回率为 0.809, mAP 为 0.828,检测速度为 18.1ms。相比之下,MS-YOLOv5s 在 9.5ms 的检测速度下,召回率达到 0.989, mAP 达到 0.998,相比 YOLOv5 提高了 17%。改进后的方法相比 YOLOv5 在召回率和 mAP 上有大幅提升,召回率最多提升了 27.8%, mAP 最多提升了 28.2%。

表 2 给出了模型改进前后在 Bosch 数据集上的测试结果,并与其他方法进行对比。YOLOv5 算法作为较新的目标检测算法,相比 Faster RCNN 和 SSD 的改进方法具有更好的检测能力、更快的检测速度。MS-YOLOv5 与 YOLOv5 同级别模型相比,检测性能均有所提高, mAP 最少增加了 6.5%,达到 0.673,拥有对比算法中最高的检测能力。改进




Fig. 6 Detection results of YOLOv5 and MS-YOLOv5 in backlight scenes

图6 YOLOv5 与 MS-YOLOv5 在逆光场景下的检测结果



Fig. 7 Detection results of YOLOv5 and MS-YOLOv5 in night scenes

图7 YOLOv5 与 MS-YOLOv5 在夜晚场景下的检测结果




Fig. 8 Detection results of YOLOv5 and MS-YOLOv5 in dusk scenes

图8 YOLOv5 与 MS-YOLOv5 在黄昏场景下的检测结果



Fig. 9 Detection results of YOLOv5 and MS-YOLOv5 for small objects

图9 YOLOv5 与 MS-YOLOv5 对小目标的检测结果

Table 1 Results of model on our dataset

表1 本文数据集上模型测试结果

Model	Recall	mAP	红灯 (AP)	黄灯 (AP)	绿灯 (AP)	None (AP)	Time (ms)
YOLOv5s	0.716	0.716	0.868	0.462	0.839	0.695	7.6
YOLOv5m	0.800	0.805	0.927	0.575	0.917	0.802	9.8
YOLOv5l	0.802	0.808	0.915	0.587	0.920	0.812	12.2
YOLOv5x	0.809	0.828	0.929	0.635	0.934	0.816	18.1
MS-YOLOv5s	0.989	0.998	0.993	0.986	0.989	0.983	9.5
MS-YOLOv5m	0.994	0.991	0.993	0.993	0.990	0.987	12.0
MS-YOLOv5l	0.994	0.991	0.993	0.988	0.994	0.990	14.5
MS-YOLOv5x	0.994	0.991	0.992	0.993	0.991	0.987	21.7


方法在大幅提高模型检测能力的同时,对速度的影响仅约为 2ms。Bosch 数据集的测试结果表明,改进模型在其他交通灯数据集上同样适用,并优于其他模型。

Table 2 Results of model on Bosch dataset

表 2 Bosch 数据集上模型测试结果


Model	mAP	red (AP)	yellow (AP)	green (AP)	none (AP)	Time (ms)
SSD Mobilenet V1 ^[15]	0.410	0.550	0.410	0.680	0.0	38
Faster RCNN NASA ^[15]	0.430	0.660	0.330	0.710	0.0	~1 560s
YOLOv5s	0.532	0.756	0.466	0.907	0.0	6
YOLOv5m	0.577	0.828	0.591	0.887	0.0	8
YOLOv5l	0.564	0.809	0.536	0.908	0.0	15
YOLOv5x	0.608	0.826	0.685	0.919	0.0	23.7
MS-YOLOv5s	0.61	0.824	0.691	0.926	0.0	7.1
MS-YOLOv5m	0.644	0.85	0.785	0.942	0.0	9.4
MS-YOLOv5l	0.662	0.849	0.882	0.917	0.0	17.7
MS-YOLOv5x	0.673	0.850	0.894	0.940	0.0	25.6

为探究模型对不同类别交通灯的检测能力,本文测试了不同类别的 AP 值(见表 1),并绘制了 YOLOv5 和 MS-YOLOv5 的 PR 图。从表 1 中可知,YOLOv5s 对黄灯的 AP 值仅有 0.462,YOLOv5x 对黄灯的 AP 也仅有 0.635。改进后模型对所有类别的检测能力都有显著提高,其中 AP 值最低也可达到 0.983,最高为 0.994。如图 10(a)所示,YOLOv5l 对红灯和绿灯的检测能力一般,对黄灯和 None 的检测能力严重不足。如图 10(b)所示,MS-YOLOv5l 对所有类都有很好的检测能力,PR 曲线逼近右上方。



(a) PR curve of YOLOv5l

(a) YOLOv5l 的 PR 曲线图



(b) PR curve of MS-YOLOv5l

(b) MS-YOLOv5l 的 PR 曲线图

Fig. 10 PR curve of YOLOv5l and MS-YOLOv5l on the test set

图 10 YOLOv5 与 MS-YOLOv5 在测试集上的 PR 曲线图

3.3 消融实验

通过构建消融实验,可逐步探究改进方法对模型的有效性。实验以 YOLOv5l 为基础模型,逐步引入改进方法,并在本文数据集上测试模型召回率和 mAP,将结果记录在表 3 中。

Table 3 Ablation experiments based on YOLOv5l

表 3 以 YOLOv5l 为基础模型的消融实验

mosai	our augment	multiscale training	our FPN	Recall	mAP
-	-	-	-	0.802	0.808
✓	-	-	-	0.864	0.852
-	✓	-	-	0.873	0.860
-	-	✓	-	0.859	0.866
-	-	-	✓	0.856	0.848
-	✓	✓	-	0.911	0.907
-	✓	✓	✓	0.994	0.991

没有进行数据增强的 YOLOv5 对交通灯检测的 mAP 只有 0.808,在使用 YOLOv5 自带的 mosaic 数据增强条件下,mAP 提升了 4.4%。在使用本文提出的数据增强方法后,mAP 提升了 5.2%,召回率更是提升了 7.1%。因此,数据增强对于 YOLOv5 十分关键,可大幅提高模型召回率。引入多尺度训练后,模型的 mAP 和召回率都有所改善,其中 mAP 提升了 5.8%,达到 0.866。使用多尺度特征融合后,模型检测能力提升不够显著,mAP 提升了 4%。相比与其他几种改进方法,mAP 和召回率的提升幅度较小。

通过逐步引入改进方法,模型检测能力也随之得到提升,最终 mAP 达到 0.991,召回率达到 0.994。可发现在经过数据增强和多尺度训练后,多尺度特征融合效果显著增加,召回率提升了 8.3%,mAP 提升了 8.4%,相比单独使用多尺度特征融合的效益更高。

4 结语

由于国内缺乏交通灯数据集,本文采集了现实场景中的交通灯图像,制作了交通灯数据集。针对交通灯检测存在的尺度小、环境复杂等难点,提出多尺度 YOLOv5 的交通灯检测方法:首先使用数据增强方式对模型输入增强,增加图像的复杂度,提高模型的鲁棒性;然后针对模型输入尺度提出多尺度训练方式,增加模型对不同尺度的检测能力;最后提出一种多尺度输出的特征融合方式,并使用远跳传递低级特征信息,有效提升了模型对小目标的检测能力。实验结果表明,多尺度 YOLOv5 增加了少量推理时间,大幅提升了模型的召回率和 mAP,模型的鲁棒性也得到提高,实现了对国内交通环境中交通灯的实时、准确检测。本文下一步工作是将该算法与行人检测、车辆检测与车道线检测算法相结合,构建自动驾驶汽车周围环境快速检测系统。

参考文献:

- [1] ILLINGWORTH J, KITTLER J. The adaptive hough transform[J]. IEEE

- Transactions on Pattern Analysis and Machine Intelligence, 1987 (5): 690–698.
- [2] DUAN K B, KEERTHI S S. Which is the best multiclass SVM method? an empirical study[C]// Proceedings of the International Workshop on Multiple Classifier Systems, 2005: 278–285.
- [3] TRAPNELL C, PACTHER L, SALZBERG S L. TopHat: discovering splice junctions with RNA-Seq[J]. Bioinformatics, 2009, 25(9): 1105–1111.
- [4] TIAN J, YING J, ZHU D D. A new method of arrow traffic lights recognition[J]. Electronic Science and Technology, 2015, 28(11): 150–153.
田谨, 应捷, 朱丹丹. 一种新的箭头形交通信号灯识别方法[J]. 电子科技, 2015, 28(11): 150–153.
- [5] YE F, LIU Z L. Pedestrian detection based on improved YOLOv3 algorithm[J]. Electronic Science and Technology, 2021, 34(1): 5–9, 30.
叶飞, 刘子龙. 基于改进YOLOv3算法的行人检测研究[J]. 电子科技, 2021, 34(1): 5–9, 30.
- [6] REDMON J, FARHADI A. Yolov3: an incremental improvement[DB/OL]. <https://arxiv.org/abs/1804.02767>.
- [7] YAN G Y, LIU Z X, XIONG Y Y, et al. Sharing bicycle's categories and parking violation detection based on object detection and semantic segmentation[J]. Computer Application Research, 2020, 37(10): 3175–3179.
严广宇, 刘正熙, 熊运余, 等. 基于目标检测和语义分割共享单车类别与违停检测[J]. 计算机应用研究, 2020, 37(10): 3175–3179.
- [8] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards realtime object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39: 1137–1149.
- [9] ZHU Z, LIANG D, ZHANG S, et al. Traffic sign detection and classification in the wild[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2110–2118.
- [10] KIM H K, PARK J H, JUNG H Y. An efficient color space for deep learning based traffic light recognition[J]. Journal of Advanced Transportation, 2018(4): 1–12.
- [11] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580–587.
- [12] DAI J, LI Y, HE K, et al. R-FCN: object detection via region based fully convolutional networks[DB/OL]. <https://arxiv.org/abs/1605.06409>.
- [13] LIU J, ZHANG D. Research on vehicle object detection algorithm based on improved YOLOv3 algorithm[C]// Zhejiang: Proceedings of the Journal of Physics: Conference Series, 2020.
- [14] Ultralytics. YOLOv5[EB/OL]. <https://github.com/ultralytics/yolov5>.
- [15] BEHRENDT K, NOVAK L, BOTROS R. A deep learning approach to traffic lights: detection, tracking, and classification[C]// Proceedings of the 2017 IEEE International Conference on Robotics and Automation, 2017: 1370–1377.
- [16] YU F, XIAN W, CHEN Y, et al. Bdd100k: a diverse driving video database with scalable annotation tooling[DB/OL]. <https://arxiv.org/abs/1805.04687>.
- [17] GEIGER A, LENZ P, STILLER C, et al. Vision meets robotics: the KITTI dataset[J]. The International Journal of Robotics Research, 2013, 32(11): 1231–1237.
- [18] CORDTS M, OMRAN M, RAMOS S, et al. The cityscapes dataset for semantic urban scene understanding[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 3213–3223.
- [19] ZHANG J, HUANG M, JIN X, et al. A real-time chinese traffic sign detection algorithm based on modified YOLOv2[J]. Algorithms, 2017, 10(4): 127.
- [20] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: optimal speed and accuracy of object detection[DB/OL]. <https://arxiv.org/abs/2004.10934>.
- [21] LIU S, QI L, QIN H, et al. Path aggregation network for in-stance segmentation[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8759–8768.
- [22] WANG C Y, LIAO H Y M, WU Y H, et al. CSPNet: a new backbone that can enhance learning capability of CNN[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 390–391.
- [23] TAN M, PANG R, LE Q V. Efficientdet: scalable and efficient object detection[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 10781–10790.

(责任编辑:黄 健)